

基于YOLO11s的COCO2017 结构化剪枝与知识蒸馏实验研究


Taylor贪心剪枝 · BN统计校准 · 多教师性能恢复

实验19正式报告

信息2404 赵泽宇

2026年9月

1 摘要



本实验围绕完整COCO2017数据集上的YOLO11s结构化压缩展开。在前期COCO128实验筛选方法的基础上，使用Taylor一阶重要性与理论计算量收益构造约5%、10%、15%和20%的嵌套剪枝阶梯，并在统一BN统计校准后，对普通微调、YOLO11s同构教师蒸馏、YOLO11m较大教师蒸馏以及DINOV2跨架构视觉特征蒸馏进行比较。

实验共完成12个正式20轮训练任务。最佳精度候选为15%节点加YOLO11s蒸馏：val2017 mAP50-95为0.4274，TP GMAC下降15.13%，参数量下降14.75%。

20%候选的val2017 mAP50-95为0.4226，TP GMAC下降20.06%，参数量下降20.98%。

相对普通微调，YOLO11s蒸馏在15%节点增加0.39 AP点，在20%节点增加0.10 AP点。因此，主要精度恢复来自检测训练本身，知识蒸馏只提供小幅附加收益。

A800上PyTorch FP32、batch=1的短前向测试没有显示理论计算量下降带来稳定延迟改善。因此，本实验验证了结构压缩和精度恢复流程，但没有证明无损压缩或实际部署加速。结果支持将15%节点作为当前精度与理论计算量的较优折中，并将20%节点保留为更高压缩候选。

核心结论：15%至20%的YOLO11s结构压缩可经20轮训练恢复至约0.42 mAP；普通微调贡献主要恢复，蒸馏提供小幅附加收益。

关键词：YOLO11s；COCO2017；结构化剪枝；Taylor重要性；知识蒸馏；DINOV2

实验研究流程



图1 COCO2017结构化剪枝与蒸馏整体流程

2 研究目标与正式实验协议

2.1 研究问题

前期小规模实验已经完成环境、剪枝依赖和蒸馏梯度链路验证，但COCO128样本量小，模型选择和结果稳定性有限。本实验转向完整COCO2017，集中回答以下问题。

- 结构压缩：YOLO11s在理论计算量减少15%至20%后，能否通过训练恢复到可用精度？
- 恢复归因：剪枝后性能提升中，普通微调和知识蒸馏分别贡献多少？
- 教师选择：三类教师在当前剪枝学生上的效果如何？
- 效率兑现：参数量与GMAC下降后，A800上的实际前向延迟是否同步下降？

2.2 固定训练配置

项目	固定设置	作用
数据	COCO2017; calibration 2048、tune 2048、recovery 114191	区分重要性估计、模型选择和训练
模型	官方YOLO11s，输入640×640	所有剪枝节点共享同一初始来源
训练	20 epochs, batch 128, AdamW, seed 42	统一恢复预算
学习率	lr0=0.001, lrf=0.1, warmup 1 epoch	统一优化条件
增强	mosaic 0.5, scale 0.3, translate 0.1, fliplr 0.5	保持各组训练公平
选择	source、best、last按tune最大值选择，再报告val	避免把最后一轮默认当作最佳

正式训练记录显示Python 3.12.11、PyTorch 2.13.0+cu132和Ultralytics 8.4.144；本次审计环境使用Torch-Pruning 1.6.1与ultralytics-thop 2.1.6复算模型结构与计算量。历史训练未保存完整Git提交和所有库版本快照，因此不能把审计时环境版本等同于严格锁定的训练环境。

3 数据划分与评价口径

3.1 数据隔离

Taylor重要性使用2048张校准图像；BN统计校准和20轮恢复训练使用114191张恢复池图像；另以2048张tune图像选择候选权重，标准val2017用于最终汇报。按实际图片文件名核查，校准集、tune集和恢复池两两交集为0。

集合	图片数	用途	是否更新参数
calibration	2048	Taylor梯度与通道重要性	仅计算梯度，不进行训练
tune	2048	节点评价和checkpoint选择	否
recovery	114191	BN统计和恢复训练	BN校准只更新统计量；训练更新学生
val2017	5000	最终精度汇报	否

3.2 指标定义

- mAP50-95：COCO主指标，对IoU 0.50至0.95多个阈值取平均，作为主要精度判断。
- 参数量：反映模型可训练张量规模，但不等同于权重文件字节数。
- GMAC：以 $1 \times 3 \times 640 \times 640$ 输入计算理论乘加量；Torch-Pruning为主口径，THOP用于同环境复核。
- AP点：mAP差值乘100。例如0.003907对应0.39 AP点。
- 延迟：A800、batch=1、FP32模型前向，不含图像预处理、数据传输和NMS。

参数量、GMAC与硬件延迟是不同指标；GMAC下降不能直接等同于部署加速。

3.3 模型选择边界

19B阶段根据已有val-GMAC结果保留15%和20%节点进入多教师比较，后续教师优劣也参考了val。因此这些val结果适合描述本批实验的相对表现，但不是完全独立于选型的最最终测试成绩。若要形成更强的泛化结论，应冻结方案后增加独立测试数据或重复随机种子。

4 Taylor嵌套结构化剪枝

4.1 方法设计

实验删除完整卷积输出通道，并通过Torch-Pruning DependencyGraph联动调整BatchNorm、后续卷积输入以及C2f和检测头中的依赖张量。候选层经过结构安全过滤，单次以8通道为剪枝步长。每个接受步骤之后重新计算Taylor重要性，并以重要性代价与GMAC收益的比值选择下一步。

Taylor通道重要性取权重与对应梯度乘积绝对值的均值；候选同时考虑重要性代价和可节省GMAC。

5%节点来自前一阶段的raw剪枝模型，10%、15%和20%节点继续沿同一raw链向下剪，构成可比较的嵌套路径。后续96个接受步骤中，10%、15%和20%阶段分别包含31、30和35步。每到一个节点会复制模型执行BN校准与评价，但校准后的副本不会送回主剪枝链，因此后续节点仍由纯raw权重继续生成。

4.2 BN统计校准

结构化剪枝改变了卷积通道，原有BatchNorm运行均值与方差可能不再匹配。实验在recovery池中统一抽取8192张图像，以momentum=0.005更新BN运行统计，不重置已有统计，不更新卷积参数，也不使用tune标签。校准后保存的权重作为各节点恢复训练的source。

节点	raw tune	BN/source tune	BN提升	source val
5%	0.514366	0.522828	+0.008462	0.425604
10%	0.431151	0.468309	+0.037159	0.386686
15%	0.195039	0.311249	+0.116210	0.258892
20%	0.053326	0.135618	+0.082292	0.117799

5%节点另有raw完整val 0.418059，校准后提升到0.425604。10%、15%和20%节点未保存raw完整val，因此本报告只比较它们在tune上的校准前后变化，不推算不存在的val校准收益。

5 剪枝阶梯结果




图2 剪枝阶梯的理论计算量下降与训练前source精度

模型	参数量	参数下降	TP GMAC	TP下降	THOP GMAC	THOP下降
官方YOLO11s	9,458,752	0.00%	10.7991	0.00%	10.8567	0.00%
5%节点	9,093,536	3.86%	10.2251	5.32%	10.2811	5.30%
10%节点	8,549,624	9.61%	9.7159	10.03%	9.7707	10.00%
15%节点	8,063,896	14.75%	9.1650	15.13%	9.2184	15.09%
20%节点	7,474,088	20.98%	8.6323	20.06%	8.6844	20.01%

主口径与复核口径都显示四个节点接近目标计算量阶梯。旧记录曾把Torch-Pruning官方基线与THOP学生数值混用；本报告使用同一工具内部计算下降比例。每个正式选中学生与其source具有相同形状摘要、参数量和两种GMAC，说明恢复训练没有改变剪枝结构。

5.1 剪枝过程的实际偏差

原计划希望按low、medium、high层级逐级开放候选层；实际脚本保留了各层级的剪枝上限，但每个阶段直接将所有上限内候选纳入搜索，没有实现逐级开放。各节点中途也执行了BN副本评价，而不是全部raw节点完成后再统一评价。由于校准副本没有回写主链，这一偏差没有污染嵌套raw路径，但需要在复现和方法解释中如实说明。

6 剪枝后性能恢复

6.1 对照组与YOLO11s蒸馏

普通微调control直接以各节点BN校准source继续训练，作为剪枝后恢复的必要基线。YOLO11s蒸馏使用冻结的官方YOLO11s作为同构教师，从P3、P4和P5提取中间特征；学生特征经训练期 1×1 投影后与教师特征计算余弦距离，三个尺度权重为0.25、0.50和0.25。KD总权重为0.5，前2轮线性升权。部署学生权重时移除教师、投影层和hook。

6.2 source、best与last选择

每个任务都评估source、训练best和last，并以tune mAP50-95最高者作为最终选中权重，再对该权重计算val指标。这一规则使5%和10%节点在训练后没有超过较强的source时能够退回source，而不是把训练失败后的best或last强行作为结果。

节点	方案	训练后最高tune	最终选中	选中tune	选中val
5%	control	0.454161	source	0.522828	0.425604
5%	YOLO11s KD	0.453540	source	0.522828	0.425604
10%	control	0.449928	source	0.468309	0.386686
10%	YOLO11s KD	0.456338	source	0.468309	0.386686
15%	control	0.448279	best	0.448279	0.423467
15%	YOLO11s KD	0.451473	best	0.451473	0.427374
20%	control	0.449289	best	0.449289	0.421530
20%	YOLO11s KD	0.443622	best	0.443622	0.422572

5%和10%任务确实完成了20轮训练，但最终按规则选回source，因此不能写成“未训练”。它们说明同一套20轮恢复配方并不适合所有剪枝深度。

7 恢复效果与收益归因




图3 15%和20%节点从source到普通微调及YOLO11s蒸馏的恢复路径

节点	source val	control val	YOLO11s KD val	训练恢复	KD额外收益
15%	0.258892	0.423467	0.427374	+16.46 AP点	+0.39 AP点
20%	0.117799	0.421530	0.422572	+30.37 AP点	+0.10 AP点

15%节点从0.2589恢复到0.4235，普通微调贡献约16.46 AP点，YOLO11s蒸馏再增加约0.39 AP点。20%节点从0.1178恢复到0.4215，普通微调贡献约30.37 AP点，蒸馏再增加约0.10 AP点。由此不能把深剪枝模型从低精度恢复至约0.42的全部收益归因于知识蒸馏。

相对历史官方基线约0.4633，15%和20%候选仍分别低约3.59和4.07 AP点。当前实验实现了可解释的精度与理论效率交换，没有达到无损压缩。由于只运行一个seed=42，0.39和0.10 AP点的差异可能受到训练波动影响，尚不能称为稳定或统计显著的蒸馏收益。

最重要的实验判断：剪枝后“恢复了多少”与“蒸馏额外贡献多少”必须分开报告。

8 多教师蒸馏比较

8.1 教师设置

教师	类型	监督特征	训练期峰值显存	目的
YOLO11s	同构检测教师	P3/P4/P5	约29.0至30.7 GiB	验证同构特征蒸馏
YOLO11m	更大检测教师	P3/P4/P5	约33.1 GiB	检验教师容量是否带来收益
DINOv2 ViT-S/14	跨架构视觉教师	Blocks 4/8/12	约35.0至35.6 GiB	检验通用视觉表征迁移

DINOv2分支将640×640的YOLO输入插值至644×644，使尺寸可被patch size 14整除。教师第4、8、12个Transformer block分别对应学生P3、P4和P5；经过空间插值与384通道投影后计算余弦距离。DINOv2没有与YOLO同构的检测输出，因此这里属于跨架构视觉特征蒸馏，不是跨模态蒸馏。




图4 15%与20%节点的多教师val2017 mAP50-95对比（纵轴从0.415起，仅用于观察小差异）

节点	control	YOLO11s KD	YOLO11m KD	DINOv2 KD
15%	0.423467	0.427374	0.424587	0.423965
20%	0.421530	0.422572	0.421673	0.421245

本次val最高的是YOLO11s，但YOLO11m和DINOv2相对普通微调的差异很小。

tune排序并不相同：15%节点YOLO11m为0.452120，略高于YOLO11s的0.451473；20%节点普通微调为0.449289，高于YOLO11s的0.443622。因此不能得出“更大教师一定更好”或“YOLO11s普遍最优”的一般性结论。

9 十二个正式任务总表

节点	方案	选中	tune	val mAP50-95	相对source	相对control
5%	control	source	0.522828	0.425604	+0.000000	+0.000000
5%	YOLO11s KD	source	0.522828	0.425604	+0.000000	+0.000000
10%	control	source	0.468309	0.386686	+0.000000	+0.000000
10%	YOLO11s KD	source	0.468309	0.386686	+0.000000	+0.000000
15%	control	best	0.448279	0.423467	+0.164575	+0.000000
15%	YOLO11s KD	best	0.451473	0.427374	+0.168482	+0.003907
15%	YOLO11m KD	best	0.452120	0.424587	+0.165695	+0.001120
15%	DINOv2 KD	best	0.445610	0.423965	+0.165073	+0.000498
20%	control	best	0.449289	0.421530	+0.303731	+0.000000
20%	YOLO11s KD	best	0.443622	0.422572	+0.304773	+0.001042
20%	YOLO11m KD	best	0.448004	0.421673	+0.303874	+0.000143
20%	DINOv2 KD	best	0.446232	0.421245	+0.303447	-0.000284

表中“相对source”只比较同一节点同一val集合；“相对control”用于隔离知识蒸馏在普通训练之外的附加效果。5%和10%最终选中source，因此其相对source为0。未入选best或last没有统一完整val，本报告不将tune与val混算。

9.1 训练资源

方案	单任务累计训练时间	峰值allocated显存
control	约1.38至1.48小时	run_info未留存
YOLO11s KD	约2.01至2.09小时	约29.03至30.69 GiB
YOLO11m KD	约2.63至2.71小时	约33.11至33.12 GiB
DINOv2 KD	约3.04至3.12小时	约35.02至35.60 GiB

训练时间取results.csv最后一行累计time，包含训练循环内部验证，不等于纯GPU核时间；也不包含后续独立checkpoint评价。显存是脚本记录的PyTorch峰值allocated，不等于nvidia-smi整卡占用。

10 理论压缩与实际延迟

模型	TP GMAC下降	历史mean	本次mean	本次median	本次P90
官方YOLO11s	0.00%	7.57 ms	7.86 ms	7.80 ms	7.90 ms
15%节点	15.13%	7.50 ms	7.76 ms	7.73 ms	7.78 ms
20%节点	20.06%	7.54 ms	7.99 ms	7.92 ms	8.10 ms

已有延迟脚本在A800上使用batch=1、640×640全零输入、eval/no_grad、30次预热和200次计时，每次前后执行CUDA同步。测试没有显式启用FP16、算子融合、编译或TensorRT，仅统计模型前向，不包括预处理、主机到显卡传输和NMS。

本次复测前两张A800均显示0%利用率和0 MiB显存占用。15%节点mean仅比官方低约0.10毫秒，20%节点反而高约0.13毫秒。历史测试也没有观察到与15%至20% GMAC下降对应的延迟收益。短前向测试不能判断瓶颈来自访存、内核调度还是结构形状，也不能外推到大batch或端侧设备。

已经证实	尚未证实
参数量下降14.75%至20.98% TP与THOP均确认理论计算量下降 恢复训练不改变剪枝结构	A800 batch=1明显加速 TensorRT或端侧部署收益 精度无损压缩

理论GMAC下降已经验证；真实部署加速不属于本报告已完成结论。

11 讨论

剪枝深度与可恢复性

15%和20%节点raw/source精度下降明显，但20轮检测训练可将两者恢复到约0.42，说明深剪枝模型仍保留了可学习结构。

蒸馏收益较小

YOLO11s蒸馏在15%和20%节点分别增加0.39和0.10 AP点。学生容量、特征投影和损失冲突可能影响收益，但本实验没有专门消融，不能将这些假设写成已证实原因。

较大教师没有形成优势

YOLO11m和DINOv2没有超过YOLO11s的val结果，说明教师容量或通用表征能力不会自动转化为检测学生收益。

浅剪枝配方退化

5%和10%的source已经较强，统一20轮训练反而降低tune，提示恢复策略需要随剪枝深度调整，而不能机械复用同一训练预算。

理论效率与硬件效率分离

结构化通道删除确实减少参数与乘加量，但当前FP32 PyTorch前向没有明显加速。报告应将其作为负结果，而不是用理论GMAC替代测速。

11.1 可信度边界

限制	影响	合理表述
单随机种子	小差异可能来自训练波动	报告观察值，不声称统计显著
val参与部分选型	不构成完全独立最终测试	限定为当前实验候选比较
未重跑官方精度	官方0.4633为历史记录	与压缩模型差距写“约”
未做TensorRT或端侧测试	不能证明部署加速	只报告PyTorch前向和理论计算量
层级逐步开放未实现	执行与原计划有偏差	明确记录实际搜索实现

12 结论与后续工作

12.1 主要结论

1. 完成了完整COCO2017上的Taylor结构化剪枝、BN统计校准、普通微调和多教师特征蒸馏流程。
2. 建立了约5%、10%、15%和20%的嵌套计算量阶梯，并通过两种工具复核模型参数与GMAC。
3. 15%加YOLO11s KD取得本次最高压缩模型val 0.4274；20%候选达到0.4226并提供更低理论计算量。
4. 普通微调是深剪枝模型恢复的主要来源，YOLO11s蒸馏只提供小幅附加收益。
5. 当前A800短前向测试没有证实明显加速，因此实验结论应限定为结构压缩和精度恢复。

12.2 当前模型选择

用途	建议模型	依据
强调精度与压缩平衡	15%节点 + YOLO11s KD	val 0.4274；GMAC下降15.13%
强调更高理论压缩	20%节点 + YOLO11s KD	val 0.4226；GMAC下降20.06%
严谨对照	对应节点control	用于隔离蒸馏相对普通训练的收益

12.3 后续工作

若继续研究，优先对15%节点补充多个随机种子，确认0.39 AP点的蒸馏收益是否稳定。其次可将方法迁移至交通目标、无人机或多传感器感知数据。TensorRT和端侧部署属于可选的工程闭环，不是当前报告成立的必要条件。

本实验已经形成完整、可复核的COCO2017项目结果；后续研究应围绕新假设展开，而不是继续无边界搜索教师或剪枝比例。

附录A 关键权重与复现材料

对象	路径或SHA256
官方YOLO11s / 教师	85a76fe86dd8afe384648546b56a7a78580c7cb7b404fc595f97969322d502d5
15% YOLO11s KD	2441f27a86b5e04046b409a367b1df4cee730703f98b1778c85433ccf5601404
20% YOLO11s KD	7ed225d564cd29ee96504a730f58d59be658772f426f2987c118ff7e017cad4a
YOLO11m教师	d5ffc1a674953a08e11a8d21e022781b1b23a19b730afc309290bd9fb5305b95
DINOv2教师	b938bf1bc15cd2ec0feacf3a1bb553fe8ea9ca46a7e1d8d00217f29aef60cd9

材料	项目内位置
正式核验报告	reports/experiment19_final_comparison.md
原实验计划	reports/experiment19_pruning_ladder_distillation_plan.md
完整结果CSV	reports/experiment19_audit/20260918_101935/comparison_full.csv
权重清单与哈希	reports/experiment19_audit/20260918_101935/checkpoint_manifest.csv
审计数据	reports/experiment19_audit/20260918_101935/audit.json
延迟复测记录	reports/experiment19_audit/20260918_101935/latency_recheck.txt

附录B 排除运行

正式比较只包含12个status=complete且epochs=20的任务。两次预检、两次失败运行和一次单轮KD测试均未计入结果。4个control任务的run_info曾因报告阶段KeyError而事后补全状态；它们均保留20行results.csv和comparison.csv，但事后补写的完成时间不能作为原始训练结束时刻。

附录C 权重说明

审计实际读取13个不同权重文件，重新计算SHA256和参数量，并分别以Torch-Pruning和THOP复算GMAC及形状摘要。所有正式选中学生与各自source结构一致，且没有残留教师、投影层或训练期模块。完整12任务路径与哈希见checkpoint_manifest.csv。