

YOLO11 结构化剪枝与 DINOv2 蒸馏初步阶段汇报

阶段性工作梳理 实验结果复盘 后续研究计划

2026 年 9 月

1 摘要

围绕轻量目标检测模型压缩开展学习与实验，已完成 YOLO11 结构化剪枝和 DINOv2 特征蒸馏的初步流程。在 COCO128 上比较了 L1、L2、Taylor 等通道重要性准则，以及普通微调、SFP 等剪后恢复方法。同等剪幅下 Taylor 表现最好；SFP 恢复精度最高，但剪幅相对较小。蒸馏部分完成了 P4 单尺度与 P3、P4、P5 多尺度方案，当前 P4 单尺度效果相对更好。

现阶段剪枝与蒸馏带来的整体提升有限，初步判断与数据规模较小、训练预算有限以及教师特征与检测特征匹配不足有关。此外，已借助 AutoDL 平台完成 COCO2017 的初步训练尝试。目前已掌握从基线建立、敏感度分析、结构化剪枝、性能恢复到特征蒸馏的完整流程。下一步将在 COCO2017 上开展统一剪幅、多随机种子和更充分训练预算下的验证，并继续从通道重要性建模与蒸馏特征对齐两个方向寻找改进点。

实验报告研究流程



图 1 YOLO11 结构化剪枝与 DINOv2 蒸馏整体流程

2 研究目标与技术路线

本次尝试关注边缘部署场景下目标检测模型的压缩问题，目标是在可控精度损失下减少参数量和计算量，并探索通用视觉教师能否帮助剪枝后的检测模型保持性能。研究顺序遵循先建立可靠基线、再压缩结构、最后恢复性能的原则。

表 1 研究阶段与当前状态

阶段	数据与模型	主要任务	当前状态
流程验证	COCO8 YOLO11n	环境配置与训练验证	已完成
小规模剪枝	COCO128 YOLO11n	敏感度 独立法 贪心法 梯度分档	已完成
大数据尝试	COCO2017 YOLO11s	基线 敏感度 贪心剪枝	已完成一轮
剪枝后蒸馏	COCO128 剪枝 YOLO11n	P4 单尺度与 P3 P4 P5 多尺度 DINOv2	已完成
正式复核	完整 COCO2017	统一对照 多随机种子 稳定测速	下一阶段

核心链路为：官方 YOLO 权重建立基线，利用敏感度分析筛选候选层，通过 Torch Pruning DependencyGraph 实施结构化通道删除，完成剪枝后恢复训练，再以冻结的 DINOv2 ViT S 14 为教师开展特征蒸馏。部署时删除教师、投影层和 hook，只保留纯 YOLO 学生模型。

3 结构化剪枝

3.1 方法设计

实验以 Ultralytics YOLO11、PyTorch 和 Torch-Pruning 为主要环境。先用 COCO8 验证训练链路，再在 COCO128 上建立固定数据配置与基线。结构化剪枝删除完整卷积输出通道，能够同时改变网络结构、参数量和理论计算量；由于卷积、BatchNorm、C2f 分支、Concat 和检测头之间存在通道依赖，项目使用 DependencyGraph 记录并联动修改依赖关系。

候选层先按结构可剪性过滤：保护首层、注意力层、检测输出层及难以安全联动的 C2f 分支，再通过逐层屏蔽 L1 最小的约 10% 通道记录 mAP50-95 下降。该步骤用于形成层级敏感度排序，屏蔽只判断趋势，不等同于真实剪枝。

- 独立法从同一基线分别构造 light balanced strong 三档模型，用于观察不同剪枝规模的影响。
- 贪心法逐步试剪候选层，以精度代价与 GMAC 收益的比值选择当前步骤，并在每步后检查前向、反向、保存和重载。
- 梯度分档法以 $\text{mean}(|W \times \partial L / \partial W|)$ 估计通道重要性，并根据 L1 敏感度为不同层设置不同剪枝比例。

3.2 COCO128 主线结果

评价同时报告 Precision、Recall、mAP50、mAP50-95、Params 与 GMACs。mAP50 采用单一 IoU=0.50，数值通常较高；mAP50-95 对 0.50 至 0.95 的多个阈值取平均，更严格，因此作为主要精度指标。Params 反映模型规模，GMACs 反映理论计算量；二者均不能直接替代同设备、同精度设置下的端到端测速。

表 2 COCO128 结构化剪枝主线结果

方案	参数减少	GMACs 减少	mAP50 95	判断
未剪枝对照	0.00%	0.00%	0.6232	基线
独立法 strong	4.17%	4.07%	0.5183	精度损失较大
贪心法 实验 05	1.69%	4.55%	0.5962	当前开发集最佳折中

方案	参数减少	GMACs 减少	mAP50 95	判断
梯度分档 A	4.17%	4.07%	0.5470	未达到预设精度要求

实验 05 相对未剪枝基线下降 0.0270，但在相近 GMACs 降幅下优于同设置复跑的独立法。其 FP32 单图网络前向中位耗时为 9.943 ms，未剪枝为 10.008 ms，差异约 0.65%，小于轮间波动，因此目前不能宣称获得稳定端到端加速。

3.3 多种通道重要性指标复评

补充实验在 held out val2017 上，以相同基线、候选层和约 3.7% 参数降幅统一比较六类准则：L1 与 L2 分别衡量权重幅值和能量，BN- γ 使用归一化层缩放系数，FPGM 根据滤波器几何冗余，Taylor 结合权重与梯度估计损失影响，HRank 根据特征图秩衡量信息量。基准 mAP50-95 为 0.386。

表 3 通道重要性准则对比

重要性指标	剪后 raw mAP50 95	微调后 mAP50 95	参数降幅
L1	0.314	0.340	3.7%
L2	0.315	0.340	3.7%
BN- γ	0.012	0.195	3.7%
FPGM	0.326	0.337	3.7%
Taylor	0.336	0.344	3.7%
HRank	未单列	0.319	3.7%

统一对比表明，Taylor 的剪后 raw 指标最高，说明梯度敏感度比单纯权重幅值更适合当前结构；FPGM 次之，L1 与 L2 接近。未经过稀疏训练的 BN- γ 表现明显较差，不宜直接用于通道删除。恢复策略方面，SFP 微调后达到 0.357，但参数降幅仅 2.6%，需要在统一剪幅下继续验证。

3.4 多种恢复手段与当前最优选择

表 4 剪枝后恢复手段对比

恢复手段	基本思路	val2017 mAP50 95	判断
普通微调	剪后继续训练以适应新结构	0.340	统一剪幅下的可靠基线
SFP 软剪枝	先归零适应 再执行硬剪枝	0.357	当前最高 但参数仅减少 2.6%
Network Slimming	BN- γ 稀疏训练后按 γ 剪枝	0.096	γ 未充分稀疏 本轮失败
KD 输出蒸馏	剪后学生对齐未剪枝教师输出	0.333	未优于普通微调
迭代剪枝	分三轮剪枝并分别微调	0.329	未优于一次性剪枝
INT8 量化	降低权重与激活精度	尚未运行	作为后续部署方向

当前选择可以分两层理解：在重要性准则中，Taylor 的剪后 raw mAP50-95 为 0.336，是统一剪幅下的最优选择；在恢复手段中，SFP 达到 0.357，为当前最高结果，但其参数降幅只有 2.6%。因此，若强调同等剪幅下的公平比较，现阶段最稳妥的组合是 Taylor 加普通微调，微调后为 0.344；SFP 作为更有潜力的恢复策略，需在相同剪幅和完整 COCO2017 上再次验证。

4 DINOv2 特征蒸馏

4.1 蒸馏结构

DINOv2 不参与剪枝，只负责剪枝后的性能恢复。学生采用实验 05 的 greedy best pt，教师采用冻结并保持 eval 状态的 DINOv2 ViT-S/14。由于通用视觉教师没有与 YOLO 对应的检测头，无法直接提供同构类别 logits，因此本项目选择中间特征蒸馏。

数据流为同一图像分别进入学生和教师：学生从 P3、P4 或 P5 取特征，经独立 1×1 卷积投影到 384 通道；教师一次前向提取 patch tokens 或指定 Transformer block 特征，空间插值后与学生特征归一化并计算 cosine distance。总损失为 YOLO 检测损失与 DINO 特征损失之和，蒸馏权重 0.5，前 2 个 epoch 线性 warm-up；教师参数和 BatchNorm 均冻结。

4.2 单尺度与多尺度设置

表 5 DINOv2 单尺度与多尺度蒸馏设置

方案	教师特征	学生特征	尺度权重	设计目的
实验 12 P4 单尺度	最终 patch tokens	P4 40×40	1.00	减少变量 兼顾语义与空间信息
实验 13 多尺度	Block 4 8 12	P3 P4 P5	0.25 0.50 0.25	同时约束多层检测特征

YOLO 输入保持 640×640 ，对应 P3、P4、P5 的空间尺寸约为 80×80 、 40×40 、 20×20 ：P3 空间细节多但语义较浅，P4 在空间信息与语义之间折中，P5 语义更强但分辨率较低。DINOv2 分支采用 644×644 ，使尺寸可被 patch size 14 整除并形成 46×46 网格，再插值到对应学生尺度。

4.3 实验结果

表 6 DINOv2 蒸馏实验结果

方案	best mAP50 95	last mAP50 95	相对普通微调 last
输入剪枝模型	0.5962	不适用	不适用
普通微调	0.5962	0.4828	0.0000

方案	best mAP50 95	last mAP50 95	相对普通微调 last
P4 单尺度 DINOv2	0.5962	0.5040	+0.0212
P3 P4 P5 多尺度 DINOv2	0.5962	0.4957	+0.0128

两种蒸馏均未刷新输入模型的 best。所有训练 epoch 都没有稳定超过起点，因此保存的 best 与输入模型一致。与此同时，last 权重有 90 个共同张量发生变化，多尺度实验的 P3、P4、P5 蒸馏损失均下降，说明训练与梯度链路实际生效。

当前结果支持的判断是：DINOv2 特征蒸馏可以缓解部分后期退化，但尚未转化为更高的检测峰值精度。P4 单尺度优于现有多尺度设置。可能原因包括训练样本过少、背景区域占比过高、CNN 与 ViT 的层级语义不完全匹配、投影层吸收了部分对齐任务，以及检测梯度与蒸馏梯度之间存在冲突。

5 已完成的探索

建立了从数据配置、训练、验证、敏感度分析、剪枝、恢复、蒸馏到部署导出的端到端流程；
关键实验固定数据划分、模型、输入尺寸、优化器、batch、epoch、device 与 seed，并保存 best、last、results 和运行日志。

- 形成了 experiments 01 至 13 的阶段记录，保留 run log run info comparison results 和权重，便于追踪参数与复现实验。
- 掌握了 YOLO11 模块依赖、结构化通道删除、剪枝后模型直接注入训练器、冻结 BatchNorm 和统一前向测速等关键工程问题。
- 完成了冻结 DINOv2 教师、特征 hook、空间与通道对齐、自定义损失、单次教师前向提取多层特征和部署清理。
- 系统整理了项目结构、剪枝原理、蒸馏原理、常见排错与答辩问题，能够从输入、损失、梯度流和输出权重解释完整实验。

6 当前问题与研究边界

表 7 当前问题及后续处理

问题	对结论的影响	后续处理
COCO128 仅 102 train 26 val	指标方差大 容易过拟合验证集	转向完整 COCO2017
同一验证集用于选层 选 best 和比较	开发集结果不能代表泛化	划分模型选择与最终评测
官方预训练模型可能见过相关 COCO 图片	小样本结果可能偏高	使用标准 val2017 统一复评
YOLO11n 冗余较少且安全层有限	当前参数和 GMACs 降幅仅约 1% 至 4%	扩展耦合层剪枝或使用更大模型
测速收益小于波动	不能声称部署加速	固定设备 精度 输入 预热和测量次数
DINOv2 是通用表征教师	特征接近不保证检测指标提高	尝试前景加权或检测教师

7 下一阶段研究计划

- 1.建立正式实验协议。在完整 COCO2017 上固定训练预算、数据增强、输入尺寸、优化器、随机种子和验证流程；至少运行多个随机种子，并报告均值与标准差。
- 2.优先复核蒸馏主假设。以同一剪枝学生比较无蒸馏与 P4 单尺度 DINOv2，保留相同初始化和训练设置，同时报告 best、last、完整曲线和蒸馏损失。
- 3.打开压缩率上限。研究 C2f split concat 的成对结构化剪枝，并在 YOLO11s 或更大模型上验证，因为较大模型通常具有更多通道冗余。
- 4.在单尺度基线稳定后再做蒸馏消融。依次考察蒸馏权重、warm up、教师层、前景掩码、损失形式和检测教师，每次只改变一个因素。

8 阶段性结论

本阶段已经完成流程和工程能力准备，并获得了可解释的正负结果。剪枝方面，现有策略能够稳定修改 YOLO11 结构，但 nano 模型和安全层限制使压缩幅度较小，真实加速尚未得到证实。蒸馏方面，DINOv2 单尺度和多尺度特征监督均已生效，但没有提高峰值精度，仅缓解了后期退化。

因此，下一步准备在完整 COCO2017 上验证少量关键假设。预期先获得可信的基线和消融结论，再决定将研究主线集中到高压压缩率结构化剪枝、剪枝后性能恢复，或两者的结合。

附录 A 关键实验与材料位置

表 8 关键实验与材料位置

内容	位置
项目总说明	README.md
学习资料总览	Summary & Learning/README.md
剪枝学习笔记	Summary & Learning/pruning.ipynb
蒸馏学习笔记	Summary & Learning/distillation.ipynb
项目结构与数据流	Summary & Learning/项目结构与数据流讲解.ipynb

内容	位置
实验 05 贪心剪枝报告	reports/experiment05_greedy_pruning.md
实验 12 单尺度蒸馏报告	reports/experiment12_dinov2_distillation_coco128.md
实验 13 多尺度蒸馏报告	reports/experiment13_dinov2_multiscale_coco128.md
剪枝方法补充复评	reports/experiment11_pruning_methods_reference.md